乳腺癌类器官偏振图像研究路径

方法论方案 第一版 2026年10月30日
本版完成研究设计与实操安排 尚未进行图像分析 模型训练或效果评测

研究目标是利用多参数偏振图像，将类器官切片中的组织划分为具有不同偏振特征的区域，量化各区域的组成和空间分布，并通过对照实验判断图信息及图表示学习是否有帮助。

一 研究范围与总体路线

已核对现有7个编号目录的文件头和变量目录：每个 FinalMM.mat 均列出 FinalM11 至 FinalM44 共16个数值阵元，以及 CalibratedM11；数值数组尺寸均为2008×2408。尚未核验全部像素的有效性、标定质量和归一化状态。

7份 info.txt 的采集路径均包含 BR-029，暂按同一来源的7个 ROI 组织探索分析。独立患者及类器官数量需要向数据提供方确认，不能把7个 ROI 直接当作7名患者。

文件与参数确认 → 组织掩膜与质量检查 → 偏振参数计算 → SLIC超像素与区域特征 → 空间图构建 → 三组方法对照 → 区域解释与异质性分析

首版选择	具体安排
计算平台	本地 Python 为主，VS Code 或 JupyterLab 查看过程；GPU用于后续GAE训练。
起始参数	PL、DL、qL、rL 四个参数；进一步计算退偏和相位延迟作为后续扩展。
比较方法	直接K-Means、SGC式特征传播后K-Means、GAE后K-Means。
分析范围	二维切片内的偏振区域与空间分布；以区域类别A、B、C等作初始命名。

本版可以明确什么

可以明确数据进入方法的方式、模块之间的关系、实验对照和结果解释边界。后续实操预计能生成参数热图、区域分布图、类别特征表、面积占比和空间指标。是否具有病理对应关系、图方法是否优于基础聚类，需要实验结果及参考标注支持。

二 数据准备与偏振参数

先统一斯托克斯分量顺序和阵元下标约定。以下采用1起始下标，并以归一化阵元 m_ij 表示公式输入。[1][2]

参数	计算公式	在本项目中的解释
PL	sqrt(m21² + m31²)	线性起偏能力，描述样本将非偏振入射光转化为线偏振成分的幅值。
DL	sqrt(m12² + m13²)	线性二向色性，描述不同线偏振入射状态的衰减差异幅值。
qL	sqrt(m42² + m43²)	与双折射有关的线性偏振向圆偏振转换幅值。
rL	sqrt(m24² + m34²)	与双折射有关的圆偏振向线性偏振转换幅值。

如果输入仍为未归一化矩阵，应按约定先取 m_ij = M_ij / M11；如果采集流程已经完成该步骤，则直接使用相应阵元。FinalM11 的变量名本身不能证明归一化是否完成。CalibratedM11 单独作为光强与结构查看通道，不与 FinalM11 默认互换。

qL、rL 不直接等于相位延迟 δ。首版使用“偏振差异”或“与双折射有关的耦合差异”描述结果。退偏、延迟及方向参数的计算，需要后续增加经核对的矩阵分解过程；方向参数还需处理角度周期性。

数据进入流程前的检查

检查项	处理安排与通过条件
文件和变量	只按名称读取需要的数值阵元；检查尺寸、缺失和非有限值。带(1)的副本先不计作新增样本。
空间对应	确认各阵元与光强图逐像素对应，保留坐标、裁剪和缩放记录。
组织掩膜	首轮建立经人工查看的组织实体掩膜；空白、培养基质与腔隙分别说明处理方式，腔隙可另作形态统计。
标定和尺度	确认切片厚度与像素尺寸。采集路径虽含20X，仍不能据此推定微米/像素。
参考信息	收集同一区域的明场、H&E或专家意见；相邻切片配准只能支持与配准精度相称的区域核对。

本批数据已存在上述变量目录，但完整数值质量尚未验证。MAT文件还包含MATLAB对象元数据，后续应显式指定变量名读取，避免把对象元数据当作图像。

三 超像素 区域特征与空间图

预处理与SLIC划分

先计算参数并建立有效组织掩膜，再为模型输入做统一的特征缩放。保留未经显示裁剪的参数数值；热图显示范围与模型特征处理分别记录。跨ROI比较时，使用共同的特征处理规则，避免每幅图单独拉伸后掩盖幅值差异。

首轮以4个偏振通道进行多通道SLIC，并以光强通道的SLIC作为敏感性比较。多参数图不是RGB颜色，使用 scikit-image 时明确关闭 convert2lab；设置组织mask并保持区域连通。[3]

项目	起始设计
超像素尺度	主设置约1000个/ROI；补充比较500和1500。实际数量受掩膜形状影响。
紧凑度	主设置1；仅在检查边界时比较0.1和10。先固定输入缩放，再讨论该参数。
核心节点特征	PL、DL、qL、rL 的区域均值与标准差，共8维。
可选特征	后续逐组增加光强纹理、局部方向等，比较是否提供额外信息。

SLIC的节点数量与最终聚类数K含义不同。节点面积、圆度会受到SLIC规则影响，因此首版不把它们直接当作组织形态；组织形态主要在最终类别的连通区域上统计。

构图规则

每个超像素是一个节点，共享边界的两个超像素之间建立无向边。每个ROI单独构图，不连接不同ROI的空间位置。GAE使用共享编码器，之后在共同表示空间内统一聚类。

图G0：空间邻接边等权。图G1：仍只连接空间邻居，以偏振特征相似度设置边权，例如 $w_{ij} = \exp(-||x_i-x_j||^2 / (2\sigma^2))$。σ 可取相邻节点特征距离的中位数；距离退化时需先检查特征，而非静默加入任意常数。

传播时为节点加入自环并归一化邻接矩阵。相似度应在统一缩放后的核心特征上计算；边权不能当作病理相似性的既定真值。

这一阶段的检查标准

在原图上查看掩膜、超像素边界和图连接。确认小结构未被大范围合并、背景未混入节点、分离组织片段之间没有错误连边。若边界明显不合理，先调整划分和掩膜，再比较模型。

四 方法对照与实验设置

方法	如何使用	主要回答的问题
M0 基础聚类	统一标准化后的8维区域特征直接进入K-Means。	已有偏振特征能区分哪些区域？
M1 图传播	Z = A_norm^t X；先用t=2，再比较t=1、3；随后K-Means。	邻域信息是否有帮助，是否出现过度平滑？
M2 图自编码器	两层GCN，8→32→16维；利用图连接重建目标学习表示，再K-Means。	可学习的图表示是否提供进一步价值？

M1借用SGC的特征传播思想，不使用原论文中的监督分类器。GAE参考标准编码器与内积解码器；编码器可使用相似度边权，重建目标先明确为二元空间连接。重建损失下降只说明模型更符合构图目标，不能直接证明区域符合组织结构。[4][5]

首轮采用的小规模实验

设置	安排
聚类数K	以K=4作为起始工程设置，比较K=3、5、6；不预设存在4种真实组织成分。
共同条件	相同ROI、掩膜、超像素、核心特征和评价单位；K-Means统一使用n_init=20。
随机性	固定并记录5个随机种子：0、1、2、3、4；报告稳定性和均值、离散程度。
GAE起始设置	150轮，Adam学习率0.001，16维表示；稀疏传播，按边采样负例，避免全像素构图。
跨ROI比较	7个图共享编码器；同一种方法统一拟合聚类中心，保持跨ROI类别定义一致。

先在G0等权空间图上比较M0、M1、M2；方法能稳定运行后，再固定其他设置，将G0替换为G1以单独观察相似度边权的作用。超像素尺度、K和传播次数分别改变，首轮不展开所有参数的组合搜索。

实验结果如何取舍

不预设GAE一定优于直接聚类。只有当特征区分、稳定性、边界保留及参考结构核对形成一致证据时，才认为某种方法有优势。不同方法的类别编号不可直接对照；展示比较时可对齐颜色，ARI本身不受编号置换影响。

DGI和VGAE列为后续扩展。首版先把上述三组比较讲清楚，再决定是否增加模型，以便将改进归因于具体环节。

五 评价指标与预期效果

评价内容	计算与解释
聚类区分程度	每个ROI报告轮廓系数；主要比较共同基础特征空间中的分数，另列各方法自身表示空间中的分数。
聚类稳定性	同一ROI、同一节点划分下，对5次运行计算两两ARI。超像素设置改变时，需映射回共同像素区域再比较。
区域组成	类别面积占比 p_c = 该类像素数/有效组织像素数，按面积加权，不能以节点比例代替。
组成多样性	$H = -\Sigma\ p_c\ \ln(p_c)$，可同时列$H/\ln(K)$。主要在相同K及掩膜规则下比较。
空间分布	统计类别连通域大小、数量、单位面积边界长度及类别接触关系；邻接关系优先按接触边界长度加权。
组织解释	展示各类参数分布和空间位置；结合原图、配准H&E或专家意见解释，有参考标注后再讨论一致性指标。
计算开销	实操时记录预处理时间、训练时间、内存和显存峰值。当前没有速度或精度实测。

Shannon熵反映组成是否均衡，不直接反映空间排列。两类各占50%时，无论左右分块还是交错分布，其熵相同，因此必须同时报告空间指标。区域更连续也可能是平滑过强，不能把边界越少直接视为越好。

首版预期可以得到的结果

技术输出：每个ROI的4种参数热图、组织与超像素检查图、3种方法的区域分布图、各类特征概况，以及面积占比和空间指标表。跨ROI采用一致处理与类别定义，可比较同一来源不同视野的组成差异。

研究结论：可检验邻接关系、相似度边权和图表示学习分别带来的变化，并找出对随机初始化及参数设置较敏感的环节。

生物学解释：能否将某类区域对应到细胞、纤维或其他结构，要以参考图像和专家核对为依据。二维切片指标不直接代表完整类器官三维结构，也暂不支持诊断准确率、癌变分级或临床效能的结论。

本轮将7个ROI共同用于探索，属于当前数据内的分析。若后续评估对新样本的适用性，应按真实的患者或类器官来源划分，并只用开发数据拟合标准化、编码器和聚类中心。

六 计算平台与后续实操安排

平台	使用方式与选择理由
本地Python 主选	NumPy/SciPy读取数值阵元，scikit-image完成掩膜与SLIC，scikit-learn完成标准化和聚类，PyTorch完成GAE。VS Code或JupyterLab用于查看过程。
实验室工作站	可迁移相同Python环境和配置，适合后续增加样本；将图像预处理和图模型训练分开执行。
Google Colab 备选	适合教学、共享Notebook或补充GPU实验。资源与运行时不保证固定，是否使用以实际访问和资源条件为准。[6]

本机已检测到约31.7 GiB内存、RTX 4060 Laptop GPU约8 GB显存，现有Python 3.11与支持CUDA的PyTorch。按每ROI约1000个超像素设计，初步判断可以在本地开展该规模研究；实际耗时和峰值占用仍需后续测量。完整图像处理以CPU逐ROI完成，GPU主要接收节点特征和稀疏图。

后续按项目建立独立环境并记录依赖版本，避免直接修改全局环境。本轮已停止未完成的环境安装，没有执行参数计算、分割、模型训练或效果评测。

阶段	完成内容	进入下一阶段的条件
1 数据与基础图像	确认归一化、坐标和像素尺度，生成参数图和经查看的组织掩膜。	公式和变量对应明确，掩膜及通道无明显异常。
2 基础区域划分	完成SLIC、8维区域特征及MO聚类，输出7个ROI检查图。	区域划分可解释，特征不被背景或异常值主导。
3 图方法对照	完成M1和M2，固定共同条件并重复运行；再检验边权。	三组结果和日志齐全，评价口径相同。
4 解释与整理	汇总空间指标、参考图核对和限制，决定是否补算退偏/延迟或增加DGI。	每项研究结论均能找到图表或实验记录支持。

开始实操前优先确认：FinalMij是否已归一化；7个ROI的真实样本关系；组织与腔隙的统计范围；是否有对应参考图像和像素标定。这些信息影响解释和比较方式，数据目录核对及方案准备可以先完成。

七 方法模块与资料依据

下面是后续实操的模块划分。本版定义输入与输出，尚未实现或运行这些模块。实验配置文件中的数值都是待验证的起始设置。

模块	输入	输出
数据与参数	FinalMM.mat、m11.mat及采集说明	参数数组、有效像素与质量记录
掩膜与超像素	光强图、参数图、人工检查的组织范围	掩膜、超像素标签及检查图
特征与空间图	参数数组、超像素标签	节点特征、节点面积、空间边及权重
表示与聚类	统一处理的特征、图和实验配置	三组类别标签、表示、聚类中心及日志
评价与解释	类别图、特征、参考图和样本关系	稳定性、面积与空间指标、可核对图表

资料与证据说明

项目范围来自用户提供的4张说明图；文件结构和样本代号来自当前数据目录及info.txt。引用的另一聊天因当前会话未提供read_thread工具而未读取，本版没有采用其未核实结论。

[1] 姚悦等 基于全偏振显微成像的数字病理技术 中国激光 2024 51(9) 0907008。重点参考2.3、3.2与3.3节。https://doi.org/10.3788/CJL231462

[2] Yao et al. Polarization imaging-based radiomics approach for the staging of liver fibrosis: supplement. Table S1. https://doi.org/10.6084/m9.figshare.19160606

[3] scikit-image 官方文档 slic 的多通道输入 mask compactness及convert2lab说明。https://scikit-image.org/docs/stable/api/skimage.segmentation.html#skimage.segmentation.slic

[4] Wu et al. Simplifying Graph Convolutional Networks. ICML 2019. https://proceedings.mlr.press/v97/wu19e.html

[5] Kipf and Welling. Variational Graph Auto-Encoders. 2016. 文中同时给出GAE。https://arxiv.org/abs/1611.07308

[6] Google Colab 官方常见问题。https://research.google.com/colaboratory/faq.html

[7] SciPy 官方文档 loadmat 的variable_names参数和MAT格式支持。https://docs.scipy.org/doc/scipy/reference/generated/scipy.io.loadmat.html

版本状态：研究设计已形成；文件头和运行环境已核对；参数图、组织掩膜、聚类结果、数值质量、训练性能及病理对应关系均待实操验证。